ОЛИМПИАДА ШКОЛЬНИКОВ «ШАГ В БУДУЩЕЕ» ПО ПРОФИЛЮ «ИНЖЕНЕРНОЕ ДЕЛО»

36057

регистрационный номер

Секция: Системы обработки информации (ИУ5)

Исследование вопроса создания чат-бота для распознавания письменных работ, сгенерированных искусственным интеллектом.

Автор: Удалов Иван Александрович

МОУ Москворецкая Гимназия, 11Б класс

Научный руководитель: Куликов Андрей Кириллович

РТУ МИРЭА

Доцент, к.т.н.

подпись научного руководителя

Исследование вопроса создания чат-бота для распознавания письменных работ, сгенерированных искусственным интеллектом.

Аннотация

На сегодняшний день, развитие языковых моделей искусственного интеллекта(LLM), которые обучены на больших объемах информации позволяет генерировать тексты высокой точности. Явным примером, является студент РГГУ, который сгенерировал большую часть бакалаврской дипломной работы с помощью LLM ChatGpt от OpenAI. Таким образом, создание доступного и простого в обращении сервиса для анализа текста на искусственную генерацию является актуальными. Целью данной работы является создание инструмента, позволяющего определить, написан текст искусственным интеллектом или человеком.

В работе проанализированы языковые модели и созданы большие корпусы текста для анализа. Основываясь на библиотеках NLTK, Razdel, Pandas, NumPy и языке Python, был проведен анализ текстовых данных и изучена базовая нейросетевая модель word2vec для токенизации и стемминга. В ходе исследования были использованы современные нейросетевые модели для детектирования сгенерированных текстов. Разработан чат-бот для анализа текста с использованием библиотеки python pyTelegramBot. Результаты исследования показали, что учитель без применения разработанного программного обеспечения распознает сгенерированный текст с ошибкой в 70%, а с приложением ошибка распознавания сгенерированного текста снижается до 20%.

В рамках работы новым является разработка программного обеспечения по проверки авторства текстового документа на основе телеграмм бота, тестирование программного обеспечения и экспериментальная проверка на фокус-группе.

По результатам работы, было разработано действующее программное решение. В дальнейшем, будут выполнены работы по увеличению объема информации для анализа, возможность загрузки различных форматов текстовых документов для анализа.

Содержание

1. Введение	5
2. Проведение анализа схожих технических решений	7
3. Методы анализа текстовой информации	10
4. Процесс создания векторов слов	11
5. Анализ текстовой информации с помощью нейронных сетей	14
6. Программная реализация	15
7. Экспериментальное подтверждение результата	19
8. Заключение	20
9. Список использованных источников	21

Введение

Научно-технический прогресс не стоит на месте, постоянно вводя в обиход новые средства для упрощения и повышения качества повседневной жизни среднестатистического человека. Одним из таких изобретений стали нейронные сети - модели, пытающиеся повторить интеллектуальную деятельность мозга. Нейронные сети и искусственный интеллект используют для решения огромного ряда задач, к их числу относятся: решение математических проблем, создание изображений по заданному тексту, а также написание оригинального качественного текста (сочинения, эссе, статьи и др.)

Однако, на данный момент именно из-за нейронных сетей могут возникнуть серьезные проблемы в образовательной системе, так как списать сочинение, которое пройдет проверку на оригинальность, стало в разы легче. Примером может служить защита выпускной квалификационной работы бакалавра РГГУ[1], которая была написана с помощью применения нейронных сетей, а точнее генеративных языковых моделей(LLM). Данная история получила продолжение, поскольку студента хотели лишить звания бакалавра. По данной повестке выступил министр науки и высшего образования Российской Федерации Валерий Фальков: "Он просто проверил систему на прочность, на мой взгляд. Это первый момент. А второй очень важный момент: вот такого рода ситуации, случающиеся внезапно, — хотя вроде бы об искусственном интеллекте, о нейросети и о ее возможностях известно давно — показывают, что университетам надо перестраиваться", — пояснил министр[2]. Таким образом, по выше приведенной информации можно сделать вывод о необходимости инструмента, способного проверять текст не только на заимствования информации в интернете, но и на сгенерированность текста.

Кроме этого, ряд статей [3-5] повествуют о разнообразных случаях подобного использования LLM и в звене среднего образования.

Можно сделать вывод, что создание инструмента, позволяющего определить, написан текст нейронной сетью или человеком является актуальной задаче.

Проблема:

Использование моделей генерации текстовых сообщений для создания письменных работ, таких как: эссе, сочинение, реферат, части выпускных дипломных работ, статьи и другие, в среде среднего и высшего образования.

Цель работы:

Создание инструмента, позволяющего определить, написан текст нейронной

сетью или человеком.

Задачи работы:

- 1. Анализ моделей генерации текста;
- 2. Изучение основ анализа текстовых данных;
- 3. Реализация прототипа системы анализа письменных работ;
- 4. Разработка пользовательского интерфейса программного обеспечения;
- 5. Тестирование разработки.

В рамках первой первой главы, анализ информации о языковых моделях для генерации текса и программном обеспечении для распознавания сгенерированного текста языковыми моделями.

Во второй главе, изучение основ анализа текстовых данных, таких как токенизация и стеммизация текстовых данных с помощью библиотек NLTK, Razdel, Pandas, NumPy языка высокого уровня Python в фреймворке PyCharm.

В третьей главе, дообучение современных моделей, размещенных на сайте Hugging Face с целью возможностью анализа русского текста.

В четвертой главе, разработка алгоритма работы чат бота, реализация чат бота с помощью библиотеки python pytelegrambot.

В пятой главе, тестирование сгенерированных текстов с помощью моделей YandexGPT, GigaChat и ChatGPT, а также людьми на предмет решения задачи классификации и определение точности разработанного программного решения.

По результатам работы, было разработано действующее программное решение. В дальнейшем, будут выполнены работы по увеличению объема информации для анализа, возможность загрузки различных форматов текстовых документов для анализа.

ПО, необходимое для решения проблемы:

- 1. PyCharm интегрированная среда разработки для языка программирования Python.
- 2. Transformers библиотека для ЯП Python 3 для доступа к моделям HuggingFace
- 3. TensorFlow библиотека для ЯП Python Здля обучения искусственных нейронных сетей

Проведение анализа схожих технических решений

В эру постоянного развития искусственного интеллекта, языковые модели (LLM) стали фундаментальным инструментом для генерации уникального контента. В таблице ниже приведены наиболее распространенные и эффективные LLM.В связи с этим, неотъемлемым компонентом стали инструменты распознавания контента, созданного искусственным интеллектом. Эти инструменты не только позволяют эффективно анализировать и классифицировать сгенерированный контент, но и вносят существенный вклад в сферу контроля качества.

В таблицах представлены самые популярные LLM (таблица 1) и, параллельно, инструменты распознавания контента, сгенерированного LLM (таблица 2), предоставляя краткий обзор их достоинств и недостатков. Эта комплексная аналитика поможет лучше понять влияние LLM на генерацию контента и роль инструментов распознавания в обеспечении его точности и соответствия требованиям пользователей.

Таблица 1 — Сравнение существующих популярных генеративных моделей с возможностью создания текстовых работ.

Название LLM-модели	Описание	Плюсы	Минусы
GPT-3 от OpenAI	GPT-3 - это мощная модель, способная генерировать текст и выполнять разнообразные задачи NLP.	-Генерация текста и ответов на вопросыПоддержка разных языков, включая русскийШирокий спектр применения -Доступность онлайн.	-Возможность создания неточных или вводящих в заблуждение ответовНе всегда умение понимать сложный контекстВопросы конфиденциальности данныхОграничения доступа в определенных регионах
Bard от Google	Google Bard AI - это одна из самых передовых моделей искусственного интеллекта, созданная Google на основе алгоритмов глубокого	-Высокая скорость и эффективность поискаХорошее понимание контекста запросов.	-Зависимость от подключения к интернету для некоторых функцийОграниченная доступность в

	обучения.	-Возможность работы офлайн.	определенных регионах и на определенных устройствах.
Megatron от NVIDIA	Медаtron - большая и масштабируемая модель глубокого обучения, разработанная компанией NVIDIA.	-Высокая производительность в обработке больших моделей и данныхПоддержка масштабируемости и обучение глубоких нейронных сетей.	-Требует мощных вычислительных ресурсов и графических процессоров (GPU)Сложность использования и настройки для неспециалистов.
T5 (Text-to- Text Transfer Transformer) от Google	Т5 - модель, которая представляет текстовые задачи как задачи перевода текста в текст.	- Обобщает разные задачи как задачи переводаЭффективен в решении разных NLP-задач.	- Требует много данных и вычислительных ресурсовНетривиальный подход для среднестатистического пользователя
Yandex GPT от Yandex	Yandex GPT - модель, разработанная Yandex для генерации текста и ответов на вопросы	-Поддержка русского языка -Доступность	-Ограничения в точности -Меньший по сравнению с другими моделями функционал
GigaChat от Сбербанка	GigaChat - чат-бот от Сбербанка, основанный на генеративной нейросети. Он может отвечать на вопросы, поддерживать диалог, писать тексты и картинки на основе описания.	-ДоступностьАктуальность данных. годаБыстрый откликВозможность использования в различных сферах.	-Возможность создания неточных или вводящих в заблуждение ответовВозможность создания вредоносного контентаВозможность автоматизации задач, выполняемых людьми Эффективность ниже прочих моделей
Ernie от Baidu	"ERNIE" (Enhanced Representation through kNowledge Integration) — модель глубокого обучения, разработанная компанией Baidu.	-Производительность в NLP -Многоязычность	-Вычислительная сложность -Сложность в fine-tuning -Вероятность сбора данных.

LLama от	LLaMA (Large Language	-Обучение на	-Ограничения доступа в
Meta	Model Meta AI) – это	двадцати разных	некоторых регионах
	исследовательский	языках с упором на	-Сложность
	инструмент, который	латиницу и	использования и
	помогает выявлять узкие	кириллицу	настройки для
	места языковых моделей	-Меньшее	неспециалистов
	искусственного интеллекта.	потребление	
		вычислительной	
		мощности	
		-Предоставление	
		исходного кода	

Таблица 2 — Сравнение существующих сервисов для распознавания искусственно сгенерированного текста.

Название	Краткое описание	Плюсы	Минусы
инструмента			
Turnitin	Turnitin - Система	-Высокая	-Стоимость использования.
	обнаружения текста,	точность	-Ограничения
	созданного	-Предоставление	конфиденциальности
	продвинутым ИИ	обратной связи	данных.
		студентам.	-Ограничения работы в
			зависимости от региона
GLTR	GLTR обеспечивает	-Высокая	-Отсутствие русской
	подробный анализ	точность	локализации
	данного текста на	-Наглядность	-Непонятный
	предмет причастия	работы	неподготовленному
	языковых моделей к		пользователю интерфейс
	его созданию		
GPT-2 Detector	GPT-2 Detector -	-Обширный	-Ограниченность
	инструмент	анализ контента	обучающих данных
	обнаружения текста,	-Быстрые	-Ложные срабатывания
	созданного с	результаты	-Зависимость от
	помощью технологии		алгоритмов
	ИИ. Создан и обучен		-Неустойчивость к новым
	OpenAi.		моделям.
GPTZero	GPTZero -бесплатный	-Бесплатный.	-Точность может быть
	онлайн-инструмент	-Просто в	ниже, чем у других
	для определения	использовании. и	инструментов
	текста, написанного	навыков.	Неспособность определять
	нейросетью	-Доступность.	текст, сгенерированный
			другими нейросетями,
			кроме GPT-3

На основе представленных выше данных можно сделать заключение о необходимости использования языковых моделей (LLM) для проверки

эффективности разработанного метода в области генерации текстов. В частности, рекомендуется применять LLM, способные создавать текстовые работы на русском языке. Эффективность тестирования решения будет наиболее заметной при использовании передовых языковых моделей, доступных для использования в России, таких как YandexGPT и Gigachat. Кроме этого, будет проведены тесты текстов, сгенерированных GPT-3, имеющим мировую популярность. Параллельно, следует провести сравнительный анализ эффективности разработанного метода с аналогичными решениями, также доступными в России, например, GLTR и GPTZero.

Методы анализа текстовой информации.

Прежде чем перейти вплотную к вопросу анализа и создания систем оценки текста на генерацию с помощью искусственного интеллекта, необходимо проанализировать методы, которые способствовали развитию данных технологий.

Первым приемом анализа текста, являются регулярные выражения. Регулярные выражения представляют собой сильный инструмент для поиска строк, проверки их на соответствие какому-либо шаблону. Ранее с помощью данного инструмента осуществлялся поиск подстрок и анализ за счет создания многочисленного количества правил.

Более современным и иногда еще используемым способом для того, чтобы вникнуть в контекст блока текста является токенизация и стемминг, а также лемматизация.

Токенизация (иногда – сегментация) по предложениям – это процесс разделения письменного языка на предложения-компоненты. Идея выглядит довольно простой. В английском и некоторых других языках мы можем вычленять предложение каждый раз, когда находим определенный знак пунктуации – точку. В английском эта задача нетривиальна, так как точка используется и в сокращениях. Таблица сокращений может сильно помочь во время обработки текста, чтобы избежать неверной расстановки границ предложений.

Лемматизация — процесс приведения словоформы к лемме — её нормальной (словарной) форме.

Стемминг — это процесс нахождения основы слова для заданного исходного слова. Основа слова не обязательно совпадает с морфологическим корнем слова.

В данном случае мы разделяем на самостоятельные блоки, корпус текста, и

глубже их анализируем для понимания контекста.

Таким образом, мы можем простыми инструментами анализировать смысл текста. Правда, необходимо добавить, что помимо данных инструментов как таковых, необходимо использовать большое количество условных операторов для получения осмысленного вывода. Кроме этого, не хватает инструмента сравнения, для того чтобы понимать, насколько та или другая информация, или контекст преобладают и в каком количественном соотношении.

Одним из важных подходов для получения осмысленного результата является использования пространственных векторов, а именно использование word2vec инструмента.

Технология Word2Vec работает с большим текстовым корпусом и по определенным правилам присваивает каждому слову уникальный набор чисел — семантический вектор. Точно так же, если из вектора слова "король" вычесть вектор "мужчина" и прибавить вектор "женщина", получатся числа, соответствующие слову "королева".

Для этого необходимо дать информацию о векторном представлении слов. Векторное представление слов, позволяет нам отобразить семантически сходные слова в близкие друг другу вектора в некоторой модели, в то время как далекие по смыслу слова будут выглядеть по-разному. Это желаемое свойство модели, которое приведет к лучшему результату.

Процесс создания векторов слов

Теперь, обладая интуитивным пониманием, мы первым делом обсудим общие принципы действия алгоритмов word2vec, разработанная Томасом Миколов. Чтобы обучить выборку слов без заранее размеченных данных, сначала нам нужно решить несколько задач:

- 1.Создать кортежи данных в формате [входное слово, выходное слово], каждое слово представлено в виде двоичного вектора длины п, где i-ое значение кодируется единицей на i-ой позиции и нулями на всех остальных (one-hot кодировка);
 - 2. Создать модель, которая на вход и выход получает one-hot векторы;
 - 3.Определить функцию потерь, предсказывающую верное слово, чтобы

оптимизировать модель;

4.Определить качество модели, убедившись, что похожие слова имеют похожие векторные представления.

Векторы Word2Vec связывают человеческое понимание языка с машинным на рисунке 1. После того, как мы сделали семантический вектор для слова, мы применяем данный алгоритм для создания семантических векторов для предложений.

Нейронная сеть [6], используемая для изучения этих вложений слов, представляет собой сеть прямой связи с одним скрытым слоем. Входными данными для сети являются целевые слова. Ярлыки — это контекстные слова. Единственный скрытый слой будет измерением, в которое мы решим встроить наши слова.

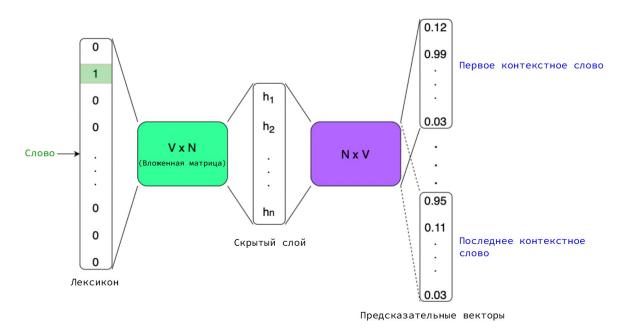


Рисунок 1 — схема работы технологии Word2Vec

Давайте рассмотрим пример того, как работает эта модель. Если мы хотим встроить слово, первый шаг — найти его индекс в словаре. Затем этот индекс передается в сети как индекс строки в матрице внедрения. На рисунке 1 входное слово является второй записью в нашем словарном векторе. Это означает, что теперь мы введем зеленую матрицу встраивания во вторую строку. Эта строка имеет длину 300 — размерность внедрения, N. Затем мы умножаем этот вектор, который является скрытым слоем, на вторую матрицу вложения формы N x V,

чтобы получить вектор длины V. Обратите внимание, что во второй матрице встраивания (фиолетовая матрица) V columns. Каждый из этих столбцов представляет слово в словаре. Другой способ концептуализировать это матричное умножение — признать, что оно приводит к скалярному произведению между вектором для целевого слова (скрытый слой) и каждым словом в словаре (столбцы фиолетовой матрицы). Результатом является вектор длины V, представляющий предсказания контекстных слов. Поскольку размер нашего контекстного окна равен 2, у нас будет 4 вектора предсказания длины V. Затем мы сравниваем эти векторы предсказания с соответствующими наземными векторами истинности, чтобы вычислить потери, которые мы распространяем обратно по сети для обновления параметров модели. В этом случае параметры модели являются элементами матриц вложения. Поскольку каждому тексту поставлен соответствие вектор в семантическом пространстве, мы можем вычислить расстояние между любыми двумя текстами как косинусную меру между ними. Имея расстояние между текстами, можно использовать алгоритм kMeans для проведения кластеризации или классификации. Только в этот раз – уже в векторном пространстве текстов, а не отдельных слов. Например, если у нас стоит задача отфильтровать из потока текстов (новости, форумы, твиты и т.д.) только имеющие интересующую нас тематику, можно подготовить базу заранее размеченных текстов, а для каждого исследуемого текста вычислять класс, к которому он тяготеет более всего (максимум усреднённой косинусной меры по нескольким лучшим вхождениям каждого класса – kMeans в чистом виде).

Некоторыми исследователями проводилась классификация с помощью данного метода ряда текстов. Классификации текстов на большое (несколько сотен) число классов, при значительном различии текстов по стилю (разные источники, длина, даже языки сообщений) и при наличии тематической связанности классов (один текст часто может иметь отношение к нескольким классам). Общая результативность подхода следующая — 90% точности на 9% классов, 99% точности на 44% классов, 76% точности на 3% классов. Эти результаты были интерпретированы следующим образом — классификатор сортирует все несколько сотен целевых классов по оценке степени соответствия текста данному классу, после чего, если мы возьмём топ 3% классов, то целевой класс окажется в этом списке с 76% вероятностью, а на 9% классов вероятность уже превысит 90%. Таким образом, данный подход может работать.

В рамках подготовки программного обеспечения по созданию модели по классификации сгенерированных и авторских текстов нами были исследованы

различные методы анализа текстов, а именно: Стемминг, лематизация и word2vec как основа для создания модели анализа текста.

Таким образом, в рамках исследования алгоритмов анализа текстовой информации было принято решение о том, что необходимо проводить анализ смысла и целостности информации с помощью заранее подготовленных нейронных сетей.

Анализ текстовой информации с помощью нейронных сетей

В рамках данного раздела было исследовано 4 готовых нейронных сетей для классификации авторства, а именно: OpenAI GPT3, OpenAI GPT4, HuggingFace Roberta-based AI text detector, HuggingFace Akshayvkt AI Detection model.

В процессе анализа для расчета количества экспериментов был использован математический аппарат теории полнофакторного эксперимента. По теории полнофакторного эксперимента было проведено 16 экспериментов на каждую нейронную суть. Поскольку по теории полнофакторного эксперимента используется формула (1)

$$N=2^{k} \tag{1}$$

где

N-количество экспериментов k-количество факторов влияющих на эксперимент

Факторы влияющие на эксперимент:

- 1. Авторство текста
- 2. Используемая нейросеть для распознавания
- 3. Объем используемой словарного запаса для нейросети
- 4. Язык написания текста

Исходя из экспериментов были получены следующие результаты:

Таблица 3 — Сравнение результатов интеграционного тестирования различных моделей с возможностью идентификации искусственно сгенерированного текста и доработки самой модели.

Название нейросети	Количество	Точность распознавания
	проведенных тестов	(%)
	(тексты, шт)	
OpenAI GPT3	16	20

OpenAI GPT4	16	13
HuggingFace Roberta-	16	28
based AI text detector		
HuggingFace Akshayvkt	16	70
AI Detection model		

Таким образом, для анализа русскоязычных текстов с целью классификации автора в дальнейшей работа будет использоваться модель HuggingFace Akshayvkt AI Detection model, поскольку по результатам 16 экспериментов обладает лучшей средней точностью, а именно 70%.

Программная реализация.

После создания и тестирования нового решения для анализа текстовых работ на предмет причастности ИИ к их созданию, было принято решение поместить продукт в оболочку с интуитивно понятным интерфейсом, где в любой момент времени пользователь идентифицировать текст.

Перед разработкой программного обеспечения была спроектирована блок схема работы алгоритма.

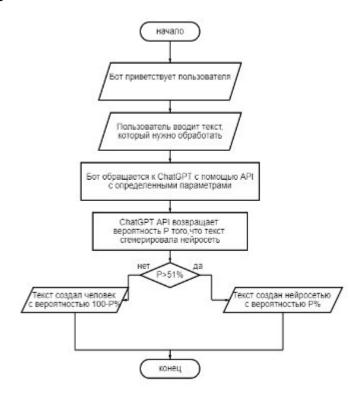


Рисунок 2 — Общая блок-схема алгоритма работы готового продукта.

По результатам разработки блок схемы, был разработан программный код чат-бот для мессенджера Telegram поскольку по сравнению с остальными мессенджерами обладает современны API и стабильной технической поддержкой, вследствие чего было принято решение о начале разработки чат-бота. Для создания чат-бота, связанного с разработанным решением использовалась библиотека для Языка программирования Python 3 "руTelegramBotApi",transformers.

Процесс разработки продемонстрирован на рисунках 2-5.

Рисунок 3 — Листинг back-end сервиса

В первую очередь был разработан back-end сервис в виде библиотеки для преобразования текста и взаимодействия с подготовленной моделью.

Рисунок 4 — Листинг кода на языке программирования Python для создания чат-

бота.

После чего был разработан второй back-end сервис, в который была интегрирована вышеописанная библиотека и библиотека Telebot для взаимодействия с Telegram Bots API.

```
Chatgottelegrambot > 17 main py 

Thipy  main py 

A plasticgahock 

B py 

A plasticgahock 

B
```

Рисунок 5 — Листинг кода на языке программирования Python для создания чатбота.

Рисунок 6 — Листинг кода на языке программирования Python для создания чат-бота.

Работа чат-бота представлена совокупностью алгоритмов, оптимизированных для получения наиболее точного и быстрого результата как для русскоязычных, так и для англоязычных текстов. В ходе работы с чат-ботом пользователь отправляет текст, который необходимо проанализировать. Первоочередно определяется язык написания текста. В случае, если текст представлен на русском языке, он переводится на английский для более точного

определения нейросетью. После этого алгоритм посылает http-запрос модели для получения анализа текста.

В результате работы был получен полнофункциональный чат-бот для мессенджера "Telegram", при "общении" с которым пользователь может получать краткий анализ письменных текстов.



Рисунок 7 — Пример работы готового продукта.

Экспериментальное подтверждение результата.

Для определения значимости исследования было решено провести эксперимент, заключающийся в сборе информации о самой доступной нейросети в России, а также о способности использования нейросетей для облегчения выполнения письменных работ моих одноклассников. Получив нужные данные и выяснив то, что большинство учеников готовы использовать нейросети на контрольных и самостоятельных работах, было решено приступить к проведению самого эксперимента.

Суть эксперимента заключалась в проведении учителем русского языка 116 класса работы по написанию сочинения-рассуждения по недавно пройденному произведению среди 26 учеников 116 класса. При этом 10 учеников сгенерировали сочинение целиком с помощью YaGPT, а остальные 16 писали сочинение сами. Для получения результатов эксперимента, учитель, осведомленный о наличии нескольких искусственно сгенерированных работ, должен был идентифицировать эти работы и определить их количество.

В результате эксперимента выяснилось, что учитель оказался способен

идентифицировать только 3 работы, созданные нейросетью, правильно. Остальные 7 сгенерированных работ он посчитал написанными аутентичным образом, а также посчитал 2 из оставшихся аутентичных работ неоригинальными.

Таким образом, в результате эксперимента выяснилось, что учитель из среднеобразовательного учреждения совершает ошибку в идентификации работы, сгенерированной ИИ в 70% случаев. Из этого следует необходимость в создании более точного инструмента для распознавания авторства ИИ при создании работы.

Однако, при применение приложения для классификации авторства текста ошибка учителя снизилась до 20%, что говорит о достижении положительного результата.

Заключение

По результатам работы удалось добиться следующих результатов:

- 1. Проанализированы существующие языковые модели для создания больших корпусов текста и их анализа
- 2. Изучены основы анализа текстовых данных, таких как токенизация и стемминг текстовых данных с помощью библиотек NLTK,Razdel,Pandas, NumPy языка высокого уровня Python в фреймворке PyCharm, а также изучена базовая модель анализа текстовой информации с помощью нейросетевой модели word2vec.
- 3. Проанализированы и использованы в разрабатываемом программном решении современные нейросетевые модели для детекции сгенерированных текстов
- 4. Разработан чат бота с помощью библиотеки python pytelegrambot, для удобного анализа текста.
- 5. Проведены исследования полученных результатов, которые показали, что учитель без применения разработанного программного обеспечения распознает сгенерированный текст ошибкой в 70%, а с приложением ошибка распознавания сгенерированного текста снижается до 20%.

Данный результат является новым, так как в открытом доступе не было найдено русифицированных приложений и чат-ботов для идентификации текста, которые были бы нацелены на массовое использование. По итогам работы над данным проектом, мною было принято решение о дальнейшем развитии данного проекта. Будущее развития проекта я вижу в решении следующих задач: Создание программы для анализа авторства текста среди учеников на основе их прошлых работ.

Дообучение и разработка собственной нейронной модели по распознаванию русских текстов.

Проведение исследований по созданию нейронной сети для анализа текста без использования интернета.

Поскольку для решения данных задач необходимо финансирование, мною принято решение о подачи заявки на грантовую программу от фонда содействия инновациям "Умник", с целью развития проекта.

Список использованных источников

- 1. URL: https://journal.tinkoff.ru/neuro-diploma/
- 2. URL: https://www.rbc.ru/society/08/02/2023/63e377ff9a79479db4184ada
- 3. URL: https://www.gazeta.ru/tech/news/2023/01/16/19494841.shtml
- 4. URL: https://www.ferra.ru/news/techlife/rossiiskie-shkolniki-nachali-spisyvat-resheniya-domashnikh-zadanii-u-neiroseti-15-01-2023.htm
- 5. URL: https://dolgoprudniy.bezformata.com/listnews/neyroseti-pomogayut-im-vipolnyat-domashnie/122733381
- 6. URL: https://mlcentre.ru/articles/651822/